

LAPORAN AKHIR PROJECT PENGOLAHAN MESIN DASAR

KLASIFIKASI KONTEN BERITA



DISUSUN OLEH :

Shafa Nasywa Dhiya (22031554013)

Devin Aulia Asshafa (22031554037)

Michael Luwi Palea (22031554055)

**PROGRAM STUDI S1 SAINS DATA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SURABAYA
2024**

PENDAHULUAN

LATAR BELAKANG

Berita merupakan salah satu konstruksi dari kehidupan nyata sosial yang selalu menggambarkan isu-isu yang sering dibahas dan dibagikan oleh masyarakat (jurnal undiksha). Dengan perkembangan teknologi informasi, jumlah berita yang tersedia secara daring meningkat pesat. Salah satu masalah yang sering muncul adalah penggunaan media digital yang luas dalam penyampaian informasi, menyebabkan jumlah berita digital yang diterbitkan oleh berbagai portal berita setiap hari menjadi sangat banyak. Hal ini mengakibatkan berita seringkali memiliki keterkaitan dengan lebih dari satu kategori (ejournal itn). Hal ini menimbulkan tantangan dalam mengklasifikasikan dan menyaring berita secara efektif. Klasifikasi konten berita menjadi penting untuk memastikan informasi yang relevan dapat diakses dengan mudah oleh pengguna.

Untuk mengatasi tantangan ini, berbagai metode kecerdasan buatan dan pembelajaran mesin telah diterapkan. Dua di antaranya adalah Multilayer Perceptron (MLP) dan K-Nearest Neighbors (KNN). MLP adalah jenis jaringan saraf tiruan yang terdiri dari beberapa lapisan neuron yang dapat mempelajari hubungan non-linear dalam data. Sementara itu, KNN adalah algoritma sederhana namun efektif yang mengklasifikasikan data berdasarkan kemiripan dengan data lain yang sudah diberi label.

Pada project kami, kami menggunakan algoritma Machine Learning yaitu Multilayer Perceptron (MLP) dan K-Nearest Neighbors (KNN) untuk mengklasifikasikan konten berita. Proses sebelum melakukan pelatihan model, akan dilakukan preprocessing yang mencakup data cleaning dan data folding agar data yang masuk pada proses pelatihan sudah bersih dan mendapatkan sistem kerja yang baik. Kemudian, dilakukan ekstraksi fitur menggunakan TF-IDF dengan tujuan bisa membantu mengurangi jumlah data berulang dengan mengukur frekuensi kemunculan sebuah kata dalam dokumen. Selain itu, kami juga akan mengevaluasi kinerja kedua model ini dengan akurasi, presisi, recall, dan f1 score. Setelah itu, dilakukan implementasi terhadap data tes untuk melihat seberapa baik model dilatih.

TUJUAN

Tujuan dari klasifikasi konten berita adalah untuk mengelompokkan berita berdasarkan kategori tertentu, sehingga mempermudah pengelolaan dan pencarian berita bagi pengelola konten dan pembaca. Dengan adanya klasifikasi, pengelola dapat mengatur artikel sesuai topik, sementara pembaca dapat dengan cepat menemukan berita yang relevan dengan minat mereka, meningkatkan pengalaman pengguna. Klasifikasi juga mendukung penyajian konten yang lebih terkurasi dan personalisasi, memungkinkan sistem untuk merekomendasikan berita berdasarkan kategori yang sering dibaca. Selain itu, pengiklan dapat menargetkan audiens dengan lebih efektif melalui iklan yang ditempatkan pada artikel sesuai kategori, dan manajemen dapat melakukan analisis tren dan preferensi pembaca dengan lebih akurat. Dalam konteks pengembangan teknologi, klasifikasi konten berita menjadi data latih penting untuk membangun model machine learning yang dapat mengkategorikan berita secara otomatis.

METODE

- 1. Data**
- 2. Pre-Processing**

3. Model

> Pelatihan Model Multilayer Perceptron (MLP)

Setelah melewati tahap ekstraksi fitur, data akan masuk ke tahap pelatihan algoritma MLP.

- Forward Propagation : Data dari setiap batch diberikan ke model, yang menghitung output dari setiap neuron dari input ke output menggunakan bobot yang diinisialisasi.
- Perhitungan Loss : Loss atau kerugian dihitung sebagai perbedaan antara output yang diprediksi oleh model dengan label yang sebenarnya dari data pelatihan. Fungsi loss seperti cross-entropy digunakan untuk masalah klasifikasi.
- Backward Propagation : Gradien loss dihitung menggunakan backpropagation, yang menyebar kembali melalui jaringan untuk menyesuaikan bobot dan bias secara iteratif untuk mengurangi loss.

> Pelatihan Model K-Nearest Neighbor (KNN)

- Penentuan Nilai K : Nilai K harus ditentukan sebelumnya. Nilai K adalah jumlah tetangga terdekat yang akan dipertimbangkan untuk menentukan kategori sebuah berita. Pemilihan nilai K dapat mempengaruhi performa model.
- Menyimpan Data Pelatihan: Semua data pelatihan disimpan dalam memori atau struktur data yang cepat diakses.
- Proses Klasifikasi: Untuk setiap sampel data uji, KNN menghitung jarak antara sampel itu dengan semua data pelatihan.
- Pemilihan Tetangga Terdekat: Model memilih K tetangga terdekat berdasarkan metrik jarak yang telah ditentukan.
- Menentukan Kategori: Dengan menggunakan mayoritas kategori dari K tetangga terdekat, model memprediksi kategori dari sampel data uji.

1. Cross Validation

Cross-validation merupakan suatu teknik yang digunakan dalam machine learning untuk mengevaluasi performa dari suatu model prediksi. Tujuannya adalah untuk mengukur seberapa baik model akan generalisasi terhadap data yang belum pernah dilihat sebelumnya. Pada project ini, kami menggunakan cross validation untuk mencari nilai K yang optimal pada model KNN.

Cross-validation digunakan untuk mengevaluasi performa model KNN dengan berbagai nilai K yang berbeda. Kami menggunakan range untuk setiap nilai K dari 1 hingga 6, model KNN dilatih dan dievaluasi menggunakan cross-validation. Nilai K yang optimal dipilih berdasarkan performa model yang paling baik, misalnya dengan menggunakan metrik seperti akurasi rata-rata dari keseluruhan fold cross-validation.

HASIL DAN ANALISIS

PEMBAHASAN

1. Preprocessing data

- Membaca dataset

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline

df = pd.read_csv('https://raw.githubusercontent.com/mekell16/Machine-Learning-Multilayer-Perceptron-/main/bbc-text.csv')
df.info()
df.isna().sum()
```

- Menampilkan plot positif dan negatif dalam dataset

```
import matplotlib.pyplot as plt

tech = (df['category'] == 'tech').sum()
ent = (df['category'] == 'entertainment').sum()
bus = (df['category'] == 'business').sum()
pol = (df['category'] == 'politics').sum()
sport = (df['category'] == 'sport').sum()
plt.bar(['tech', 'enter', 'buss', 'pol', 'sport'],
        [tech, ent, bus, pol, sport],
        color=['navy', 'pink', 'brown', 'purple', 'orange'])
plt.xlabel('Kategori')
plt.ylabel('Jumlah')
plt.title('Jumlah Negatif dan Positif dalam Dataset')

plt.show()
```

- Melakukan tokenisasi

```
import pandas as pd
from nltk.tokenize import word_tokenize
import nltk
nltk.download('punkt')

# kolom_teks = 'text'
tokenized_texts = []
for teks in df['text']:
    tokens = word_tokenize(teks)
    tokenized_texts.append(tokens)

df['tokenized_text'] = tokenized_texts
```

df

- Menormalkan teks yang telah ditokenisasi

```
import re

def normalize_text(tokens):
    # Join tokens back into a single string
    text = ' '.join(tokens)

    # Pengecilan huruf
    text = text.lower()

    # Penghapusan simbol aneh (hanya menyisakan huruf, angka,
    dan spasi)
    text = re.sub(r'^a-z0-9\s', '', text)

    # Penghapusan spasi ganda
    text = re.sub(r'\s+', ' ', text).strip()

    # Tokenisasi ulang setelah normalisasi
    normalized_tokens = text.split()

    return normalized_tokens

df['normalized_text'] =
df['tokenized_text'].apply(normalize_text)
df
```

- Menghapus stop words dari teks yang telah dinormalisasi

```
import pandas as pd
import nltk
from nltk.corpus import stopwords
nltk.download('stopwords')

# kolom_teks = 'teks_bersih'
stop_words = set(stopwords.words('english'))
def hapus_stop_words(tokens):
    # kata_kunci = teks.split() # Memecah teks menjadi
    kata-kata
    kata_tanpa_stopwords = [kata for kata in tokens if
kata.lower() not in stop_words] # Menghapus stop words
    # teks_baru = ' '.join(kata_tanpa_stopwords) #
Menggabungkan kembali kata-kata menjadi teks
    return kata_tanpa_stopwords
```

```
df['no_stopwords'] =
df['normalized_text'].apply(hapus_stop_words)
# df.to_csv('data_tanpa_stopwords.csv', index=False)
df
```

- Melakukan stemming

```
# import pandas as pd
# import nltk
from nltk.tokenize import word_tokenize
from nltk.stem import PorterStemmer, WordNetLemmatizer
nltk.download('punkt')
nltk.download('wordnet')

stemmer = PorterStemmer()
lemmatizer = WordNetLemmatizer()

# Fungsi untuk melakukan stemming pada teks
def stemming(teks):
    # kata_kunci = word_tokenize(teks) # Tokenisasi kata
    kata_stem = [stemmer.stem(kata) for kata in teks] #
    Melakukan stemming pada setiap kata
    teks_stem = ' '.join(kata_stem) # Menggabungkan kembali
    kata-kata menjadi teks
    return teks_stem

# stemming pada teks dalam kolom
df['stemmed'] = df['normalized_text'].apply(stemming)

df
```

3. Split Data

- Membagi dataset menjadi training set dan test set dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test =
train_test_split(df_tfidf_features_lemmatized, df['category'],
                  test_size
                  = 0.20,
                  random_state = 42)
```

4. Ekstraksi Fitur

- melakukan ekstraksi fitur dari teks yang telah di-lemmatisasi menggunakan TF-IDF (Term Frequency-Inverse Document Frequency) dan kemudian menampilkan hasilnya

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.model_selection import train_test_split
tfidf_vectorizer = TfidfVectorizer()
tfidf_train = tfidf_vectorizer.fit_transform(X_train)
tfidf_test = tfidf_vectorizer.transform(X_test)
print(tfidf_train.shape)
print(tfidf_test.shape)

df_tfidf_features = pd.DataFrame(tfidf_vectorizer.toarray(),
                                  columns=tfidf_vectorizer.get_feature_names_out())

# Menampilkan hasil ekstraksi fitur menggunakan TF-IDF untuk
setiap baris
for index, row in df_tfidf_features.iterrows():
    print(f"Category:      {df['category'][index]},      Text:
{df['text'][index]}")
    print("TF-IDF Lemmatized:")
    print(row)
    print("\n")
```

- menampilkan daftar fitur (kata-kata) yang dipertahankan setelah proses ekstraksi fitur menggunakan TF-IDF Vectorizer

```
# Menampilkan fitur yang dipertahankan
features = tfidf_vectorizer.get_feature_names_out()
print("Features:", features)
```

- Menampilkan distribusi nilai TF-IDF untuk beberapa fitur

```
# Menampilkan distribusi nilai TF-IDF untuk beberapa fitur
print(df_tfidf_features.describe())
```

- Menghitung Gini Index untuk setiap fitur

```
# import pandas as pd

# DataFrame yang berisi hasil ekstraksi fitur TF-IDF
# df_tfidf_features_stemmed =
pd.DataFrame(tfidf_features_stemmed.toarray())
df_tfidf_features = pd.DataFrame(tfidf_features.toarray())

# Fungsi untuk menghitung Gini Index
def gini_index(series):
    sorted_series = series.sort_values()
    n = len(sorted_series)
    coef_1 = 2 / n
```

```

        weighted_sum = (sorted_series * (n - sorted_series.index
+ 1)).sum()
        coef_2 = 1 / n
        total = sorted_series.sum()
        return coef_1 * weighted_sum / total - coef_2

# Menghitung Gini Index untuk setiap kolom dalam DataFrame
# gini_stemmed = df_tfidf_features_stemmed.apply(gini_index)
gini_lemmatized = df_tfidf_features.apply(gini_index)

# # Menampilkan Gini Index
# print("Gini Index for TF-IDF Stemmed Features:")
# print(gini_stemmed)
# print("\n")

print("Gini Index for TF-IDF Lemmatized Features:")
print(gini_lemmatized)

```

5. Menampilkan scatter plot dari Gini Index

```

# Menampilkan scatter plot Gini Index
plt.figure(figsize=(10, 6))
plt.scatter(range(len(gini_lemmatized)), gini_lemmatized,
alpha=0.6, edgecolors='w', linewidth=0.5)
plt.title('Scatter Plot of Gini Index for TF-IDF Lemmatized
Features')
plt.xlabel('Feature Index')
plt.ylabel('Gini Index')
plt.grid(True)
plt.show()

```

6. Pemodelan menggunakan MLP

```

from sklearn.neural_network import MLPClassifier

clf_ = MLPClassifier(hidden_layer_sizes=(6,5),
                      random_state=5,
                      verbose=True,
                      learning_rate_init=0.01)

clf_.fit(tfidf_train,y_train)

```

7. Evaluasi model MLP

```

from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
import seaborn as sns
from sklearn.metrics import accuracy_score

```



```

pred=clf_.predict(X_test)
confus_mat1 = confusion_matrix(y_test, pred)
print('akurasi',accuracy_score(y_test,pred))
print(classification_report(y_test,pred))

```

- Menampilkan confusion matrix

```

import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(4, 3))
sns.heatmap(confus_mat1, annot=True, fmt='d', cmap='Blues',
xticklabels=clf_.classes_, yticklabels=clf_.classes_)
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()

```

8. Prediksi teks

```

new_text_data = [
    "In an exhilarating race at the London Marathon, Kenyan athlete Eliud Kipchoge shattered the previous world record, completing the 26.2-mile course in an astonishing 2 hours and 1 minute. Kipchoge's remarkable feat has left the running community in awe, and his achievement is being celebrated worldwide",
    "Hollywood's latest sci-fi epic, "Galactic Odyssey," had its grand premiere last night. A-list celebrities, including lead actors Emma Stone and Michael B. Jordan, graced the red carpet. The film, directed by visionary filmmaker Ava DuVernay, promises mind-bending visuals and an interstellar adventure that has fans buzzing with excitement",
    "At the United Nations Climate Change Conference, leaders from 195 countries reached a historic agreement. The pact includes aggressive targets to limit global warming, reduce carbon emissions, and transition to renewable energy sources. Critics argue that implementation remains a challenge, but the commitment signals a united effort to combat climate change on a global scale",
    "Ashton Agar has become the latest Australian player to make the bold decision to become a freelance global gun-for-hire, and he couldn't be more excited about it. But the 30-year-old says he remains committed to trying to play for Australia in all three formats, including Test cricket, and

```

```

playing domestic cricket for Western Australia when he's
available despite opting not to sign a state contract for
2024-25."
]

```

```

new_tfidf =
tfidf_vectorizer_lemmatized.transform(new_text_data)
# prediksi data teks menggunakan model yang telah di buat
# (clf)
new_predictions = clf_.predict(new_tfidf)

for text, prediction in zip(new_text_data, new_predictions):
    print(f"Text: {text}\nPredicted Label: {prediction}\n")

```

9. Compare dengan KNN

- Menampilkan nilai k terbaik

```

# Mencari nilai k terbaik
k_range = range(1, 6)
k_scores = []

for k in k_range:
    knn = KNeighborsClassifier(n_neighbors=k)
    scores = cross_val_score(knn, X_train, y_train, cv=10,
scoring='accuracy')
    k_scores.append(scores.mean())

# Plot hasil
# plt.plot(k_range, k_scores, marker='o')
# plt.xlabel('Number of Neighbors K')
# plt.ylabel('Cross-Validated Accuracy')
# plt.title('KNN Accuracy for Different Values of K')
# plt.show()

# Menemukan nilai k dengan akurasi tertinggi
optimal_k = k_range[k_scores.index(max(k_scores))]
print(f'Nilai k optimal: {optimal_k}')

```

- Melatih model KNN

```

compare_knn = KNeighborsClassifier(n_neighbors=4, #
Menentukan jumlah tetangga terdekat
                                algorithm='auto', # Algoritma
yang digunakan untuk menghitung tetangga terdekat
                                weights='uniform') # Bobot
yang sama untuk semua tetangga

```

```
# Melatih model
compare_knn.fit(tfidf_train, y_train)
```

- Menampilkan plot garis yang menunjukkan bagaimana akurasi model K-Nearest Neighbors (KNN) berubah seiring dengan perubahan jumlah tetangga terdekat (K)

```
# Plot hasil
plt.plot(k_range, k_scores, marker='o')
plt.xlabel('Number of Neighbors K')
plt.ylabel('Cross-Validated Accuracy')
plt.title('KNN Accuracy for Different Values of K')
plt.show()
```

10. Evaluasi model KNN

```
pred=compare_knn.predict(X_test)
confusmat_knn = confusion_matrix(y_test, pred)
print('akurasi',accuracy_score(y_test,pred))
print(classification_report(y_test,pred))
```

- Menampilkan confusion matrix

```
import matplotlib.pyplot as plt

plt.figure(figsize=(4, 3))
sns.heatmap(confusmat_knn, annot=True, fmt='d', cmap='Blues',
xticklabels=compare_knn.classes_,
yticklabels=compare_knn.classes_)
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

11. Prediksi teks

```
new_text_data = [
    "In an exhilarating race at the London Marathon, Kenyan athlete Eliud Kipchoge shattered the previous world record, completing the 26.2-mile course in an astonishing 2 hours and 1 minute. Kipchoge's remarkable feat has left the running community in awe, and his achievement is being celebrated worldwide",
    "Hollywood's latest sci-fi epic, "Galactic Odyssey," had its grand premiere last night. A-list celebrities, including lead actors Emma Stone and Michael B. Jordan, graced the red carpet. The film, directed by visionary filmmaker Ava DuVernay, promises mind-bending visuals and an interstellar adventure that has fans buzzing with excitement",
```

"At the United Nations Climate Change Conference, leaders from 195 countries reached a historic agreement. The pact includes aggressive targets to limit global warming, reduce carbon emissions, and transition to renewable energy sources. Critics argue that implementation remains a challenge, but the commitment signals a united effort to combat climate change on a global scale",

"Ashton Agar has become the latest Australian player to make the bold decision to become a freelance global gun-for-hire, and he couldn't be more excited about it. But the 30-year-old says he remains committed to trying to play for Australia in all three formats, including Test cricket, and playing domestic cricket for Western Australia when he's available despite opting not to sign a state contract for 2024-25."

]

```
new_tfidf =  
tfidf_vectorizer_lemmatized.transform(new_text_data)  
# prediksi data teks menggunakan model yang telah di buat  
'(clf)'  
new_predictions = compare_knn.predict(new_tfidf)  
  
for text, prediction in zip(new_text_data, new_predictions):  
    print(f"Text: {text}\nPredicted Label: {prediction}\n")
```

KESIMPULAN

Project ini bertujuan untuk mengatasi tantangan dalam pengelolaan dan klasifikasi berita secara efisien dengan menggunakan teknologi machine learning. Dengan memanfaatkan Multilayer Perceptron (MLP) dan K-Nearest Neighbors (KNN), kami berhasil mengembangkan model yang mampu mengklasifikasikan artikel berita ke dalam kategori yang relevan seperti politik, ekonomi, olahraga, dan lainnya. Tahap awal melibatkan preprocessing data untuk membersihkan teks, termasuk tokenisasi, penghapusan stopwords, dan proses normalisasi. Ekstraksi fitur dilakukan menggunakan metode TF-IDF untuk mengubah teks menjadi representasi numerik yang dapat diproses oleh model.

Setelah melalui pelatihan yang cermat dan evaluasi menggunakan cross-validation, kedua model MLP dan KNN dievaluasi dengan metrik akurasi, presisi, recall, dan F1-score untuk mengukur performa mereka. Hasilnya menunjukkan bahwa kedua model dapat digunakan untuk memprediksi kategori berita dengan baik, dengan MLP menawarkan pendekatan yang lebih kompleks dan KNN memberikan alternatif sederhana namun efektif. Dengan demikian, implementasi teknologi kecerdasan buatan ini tidak hanya memberikan penyaringan informasi yang lebih baik bagi pengguna, tetapi juga berkontribusi pada pengembangan dalam pengolahan bahasa alami dan klasifikasi teks secara luas.

REFERENSI

- Alfando, & Hayami, R. (2023). KLASIFIKASI TEKS BERITA BERBAHASA INDONESIA MENGGUNAKAN MACHINE LEARNING DAN DEEP LEARNING: STUDI LITERATUR Alfando,. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 7(1), 681–686.
<https://ejournal.itn.ac.id/index.php/jati/article/view/6486/3740>
- Sudianto, Sripamuji, A. D., Ramadhanti, I., Riski Amalia, R., Saputra, J., & Prihatnowo, B. (2022). Penerapan Algoritma Support Vector Machine Dan Multi-Layer Perceptron Pada Klasifikasi Topik Berita. *Janapati*, 11(2), 84–91.
<https://doi.org/10.23887/janapati.v11i2.44151>

KONTRIBUSI

Shafa Nasywa

- Preprocessing
- Compare KNN
- Laporan
- PPT

Devin Aulia

- Ekstraksi Fitur
- Evaluasi KNN
- Laporan
- PPT

Michael Luwi

- Pembentukan model MLP
- Prediksi teks MLP dan KNN
- Laporan